

运动规划

清华大学自动化系

授课教师：李翔



清华大学
Tsinghua University

• 运动规划 (Motion Planning)

- 给定机器人的初始状态 q_s 和目标状态 q_g ，规划出适当的机器人的运动序列，使机器人能够从初始状态 q_s 运动到目标状态 q_g 。
- 根据任务不同，运动过程会具有不同的约束，例如无碰撞约束。




无人机在障碍环境中飞行



人形机器人在障碍环境中进行操作

- 运动规划 (motion Planning)
 - **路径规划 (path planning)**
 - 生成一条从初始状态到目标状态的连续路径，而不考虑和时间的关系及机器人本身的动力学。
 - 路径规划是几何问题 (geometric problem)
 - **轨迹规划 (trajectory planning)**
 - 每个轨迹点包含时间，需要考虑机器人的动力学约束。






路径规划一般是完整运动规划的基础，受课时限制，本课程主要介绍路径规划。

- **路径规划问题的定义**

- 定义机器人的**构型空间** (configuration space, C-space) 为 \mathcal{C} 。
- 一个路径规划问题需要有以下**输入**:
 - 机器人的几何和运动学描述;
 - 环境的几何描述;
 - 机器人运动的约束;
 - 机器人的初始状态;
 - 机器人的目标状态 (可以是不同的描述形式) ;
 - 对于最优规划问题, 还需要有最优化的目标: 例如使路径最短、消耗能量最少等。
- **可行路径** (feasible path) : C-space 中的一条以初始状态为起点、最终到达目标状态的不违反任何约束的连续曲线 $y(s) : [0, 1] \rightarrow \mathcal{C}$ 。
- 如果制定了**最优化**的目标, 那么得到的路径应该是最优的或者近似最优的 (optimal path or near-optimal path) 。

- **约束:**
 - 局部约束: 每个路径点自身需要满足的约束, 例如无碰撞约束等。
 - 微分约束: 对于路径的导数 (变化) 的约束, 例如喷气式飞机的转向约束。
 - 全局约束: 对于路径整体的约束, 例如无人机需要在电量耗尽前返回基地。
- **Kinodynamic planning:** 一个规划问题中既有局部约束, 也有微分约束。



- **规划算法的性能概念：**

- 完备性 (completeness)：完备性指对于可解的问题，算法能保证在有限时间内找到可行解；对于无解的问题，算法能够返回“无解”。
- 最优性 (optimality)：算法是能找到定义指标下的最优路径。
- 效率 (efficiency)：在实际问题中，算法需要多长时间来找到可行/最优路径？
- 泛化性 (generality)：算法能够求解哪类问题？不能求解哪类问题？
- 对于不同的任务，以上指标的重要性的必要性是不同的，需要具体问题具体分析。

- **构型空间：**


- 定义机器人的**构型空间** (configuration space, C-space) 为 \mathcal{C} 。
- 机器人的一个状态 q 对应 C-space 中的一个点, 即 $q \in \mathcal{C}$ 。
- 定义**工作空间** \mathcal{W} (workspace) 为机器人所在的二维 (\mathbb{R}^2) 或三维空间 (\mathbb{R}^3) 。

- **例子：**


- 平面上的质点移动机器人: $\mathcal{C} = \mathbb{R}^2$, 即二维坐标。
- 平面上的多边形移动机器人 (考虑朝向) : $\mathcal{C} = SE(2) = \mathbb{R}^2 \times SO(2)$, 即二维坐标+一维朝向, 共三维。
- 三维空间中的多面体移动机器人 (考虑姿态) : $\mathcal{C} = SE(3) = \mathbb{R}^3 \times SO(3)$, 即三维坐标+三维朝向, 共六维。
- 基座固定的具有 n 个单自由度关节的机械臂: \mathcal{C} 是 $SE(3)$ 的一个子集。因为每个关节只有一个自由度 (即有五个约束), 所以总的 \mathcal{C} 的维度为 $6n - 5n = n$ 维。

- 例子：考虑一个具有两个旋转关节（可无限旋转）的平面机械臂

$$\mathcal{Q} = \{\mathbf{q} = (q_1, q_2) : q_1 \in [0, 2\pi), q_2 \in [0, 2\pi)\}$$



平面二旋转关节机械臂的 C-space



- 若是关节最大旋转角度范围只有 2π 的机械臂呢?

- **障碍物:**

- 定义在工作空间 \mathcal{W} 中。假设有 p 个障碍物, 记它们为 $\mathcal{O}_1, \dots, \mathcal{O}_p$ 。记机器人在状态 q 时对应的在 \mathcal{W} 中的几何形状为 $\mathcal{B}(q)$ 。
- 在 \mathcal{W} 中定义的障碍物 \mathcal{O}_i 在构型空间 \mathcal{C} 中的映像被称为 $\mathcal{C} - obstacle$, 数学描述为:



$$\mathcal{CO}_i = \{q \in \mathcal{C} : \mathcal{B}(q) \cap \mathcal{O}_i \neq \emptyset\}$$

- 考虑所有障碍物, 则 \mathcal{C} -obstacles空间被定义为:





$$\mathcal{CO} = \bigcup_{i=1}^p \mathcal{CO}_i$$

- 其补集被称为自由构型空间 $\mathcal{C}_{\text{free}}$ 。

- 障碍物:



一个平面圆形移动机器人的C-obstacles



一个平面二自由度机械臂的C-obstacles


复杂

• 基于搜索的算法


- 基本思想：将 C_{free} 离散化为一个图（graph），之后在图上搜索得到路径。

• 建图方法：

- 网格搜索（grid search）
 - 分辨率影响较大。
 - 分辨率完备（resolution-complete）
- 可视图（visibility graph）
 - 若 CO_i 均为多边形，则是完备且最优的。



网格搜索



可视图

- 基于搜索的算法
 - 图搜索方法:
 - Dijkstra算法:
 - 可以得到初始节点到图中任意节点的最短路径。
 - Maintain a **container** to store all the nodes **to be visited**
 - The container is initialized with the start state X_s
 - Loop
 - **Remove** a node from the container according to some pre-defined score function
 - Visit a node
 - **Expansion**: Obtain all **neighbors** of the node
 - Discover all its neighbors
 - **Push** them (**neighbors**) into the container
 - End Loop
 - 完备且最优。
 - 没有使用目标的信息。

$v_i.g$: accumulated cost
 $v_m.prior$: 前路径点



Algorithm 1 Dijkstra 算法

```
1: Initialize priority queue  $\mathcal{Q} \leftarrow \{v_s\}$ ;  $v_s.g \leftarrow 0$ ;  $v_i.g \leftarrow \infty, v_i \in \mathcal{V} \setminus v_s$ ;  
2: while  $\mathcal{Q} \neq \emptyset$  do  
3:    $v_n \leftarrow \mathcal{Q}.pop()$ ; //  $v_n = \arg \min_{v_i} v_i.g$  ( $v_i \in \mathcal{Q}$ )  
4:    $v_n.expanded = \text{true}$ ;  
5:   if  $v_n = v_g$  then  
6:     return true;  
7:   end if  
8:   for  $v_m \in \text{Neighbor}(v_n)$  do  
9:     if  $v_m.expanded = \text{false}$  and  $v_m.g > v_n.g + c_{nm}$  then  
10:      if  $v_m.g = \infty$  then  
11:         $\mathcal{Q}.push(v_m)$ ;  
12:      end if  
13:       $v_m.g \leftarrow v_n.g + c_{nm}$ ;  
14:       $v_m.prior \leftarrow v_n$ ;  
15:    end if  
16:  end for  
17: end while  
18: return false;
```

• 基于搜索的算法

• 图搜索方法:


• Dijkstra算法:



Algorithm 1 Dijkstra 算法

```

1: Initialize priority queue  $\mathcal{Q} \leftarrow \{v_s\}$ ;  $v_s.g \leftarrow 0$ ;  $v_i.g \leftarrow \infty, v_i \in \mathcal{V} \setminus v_s$ ;
2: while  $\mathcal{Q} \neq \emptyset$  do
3:    $v_n \leftarrow \mathcal{Q}.pop()$ ; //  $v_n = \arg \min_{v_i \in \mathcal{Q}} v_i.g$ 
4:    $v_n.expanded = \text{true}$ ;
5:   if  $v_n = v_g$  then
6:     return true;
7:   end if
8:   for  $v_m \in \text{Neighbor}(v_n)$  do
9:     if  $v_m.expanded = \text{false}$  and  $v_m.g > v_n.g + c_{nm}$  then
10:      if  $v_m.g = \infty$  then
11:         $\mathcal{Q}.push(v_m)$ ;
12:      end if
13:       $v_m.g \leftarrow v_n.g + c_{nm}$ ;
14:       $v_m.prior \leftarrow v_n$ ;
15:    end if
16:  end for
17: end while
18: return false;
    
```



- 基于搜索的算法
 - 图搜索方法:
 - A*算法:
 - Dijkstra算法在探索过程中不利用目标点的信息, A*算法使用启发式的策略来更好地利用目标信息来引导搜索。
 - 对于每个节点 v_i , 除了从 v_s 到 v_i 的累积代价 $v_i.g$ 外, 还维护一个从 v_s 途径 v_i 到达 v_g 的最小估计代价 $v_i.f = v_i.g + h(v_i)$, 其中 $h(v_i)$ 指从 v_i 到 v_g 的**估计**最小代价。
 - A*算法在搜索时以 $v_i.f$ 为指标, 而Dijkstra算法中是以 $v_i.g$ 为指标。


- 基于搜索的算法
 - 图搜索方法:
 - A*算法:

Algorithm 2 A* 算法


```
1: Initialize priority queue  $\mathcal{Q} \leftarrow \{v_s\}$ ;  $v_s.g \leftarrow 0$ ;  $v_i.g \leftarrow \infty, v_i \in \mathcal{V} \setminus v_s$ ; Define  $h(v_i)$ ;
2: while  $\mathcal{Q} \neq \emptyset$  do
3:    $v_n \leftarrow \mathcal{Q}.\text{pop}()$ ; //  $v_n = \arg \min_{v_i} v_i.f$  ( $v_i \in \mathcal{Q}$ )
4:    $v_n.\text{expanded} = \text{true}$ ;
5:   if  $v_n = v_g$  then
6:     return true;
7:   end if
8:   for  $v_m \in \text{Neighbor}(v_n)$  do
9:     if  $v_m.\text{expanded} = \text{false}$  and  $v_m.g > v_n.g + c_{nm}$  then
10:      if  $v_m.g = \infty$  then
11:         $\mathcal{Q}.\text{push}(v_m)$ ;
12:      end if
13:       $v_m.g \leftarrow v_n.g + c_{nm}$ ;
14:       $v_m.\text{prior} \leftarrow v_n$ ;
15:    end if
16:  end for
17: end while
18: return false;
```

- 基于搜索的算法
 - Dijkstra算法 v.s. A*算法

<http://qiao.github.io/PathFinding.js/visual/>



Dijkstra



A*



- 基于搜索的算法

- 小结:

- 需要 C_{free} 能被显式地表达出来。
 - 适合于低维空间，例如二维或三维空间。算法复杂度随空间维度指数增长。
 - 在移动机器人上应用较多，较少应用于高自由度机械臂。



- **基于采样的算法**

- 不需要显式的 CO 表达。
- 只需可行性查询 (feasibility queries) :
 - 一个机器人状态 q 是否是可行的 (feasible) , 即 q 是否属于 CO 。
 - 两个状态之间的运动是否是可行的 (visible) (一般是两个状态之间的直线运动) 。
- 可以处理高维空间的规划问题, 例如机械臂规划。
- 最常见的两类算法:
 - 概率路标图 (probabilistic roadmaps, PRMs)
 - 快速探索随机树 (rapidly-exploring random trees, RRTs)

- 基于采样的算法

- Probabilistic roadmaps (PRM)

- 基本思想:

- 使用随机采样的方式, 建立 C_{free} 的近似路标图, 之后再使用图搜索方法得到可行路径。

- 流程:

- 在 C 中随机采样 N 个点;
 - 对采样得到的点进行 feasibility 检测; 用其中 feasible 的点以及初始状态和目标状态建立一个路标图 (roadmap), 这些点即为 roadmap 的顶点 (又称 milestones);
 - 对每个顶点, 选择它与它附近的顶点进行 visibility 检测; 将其中 visible 的边添加进图中。
 - 在图上使用图搜索方法 (例如 Dijkstra 或 A* 算法) 得到可行路径。

- 基于采样的算法

- PRM

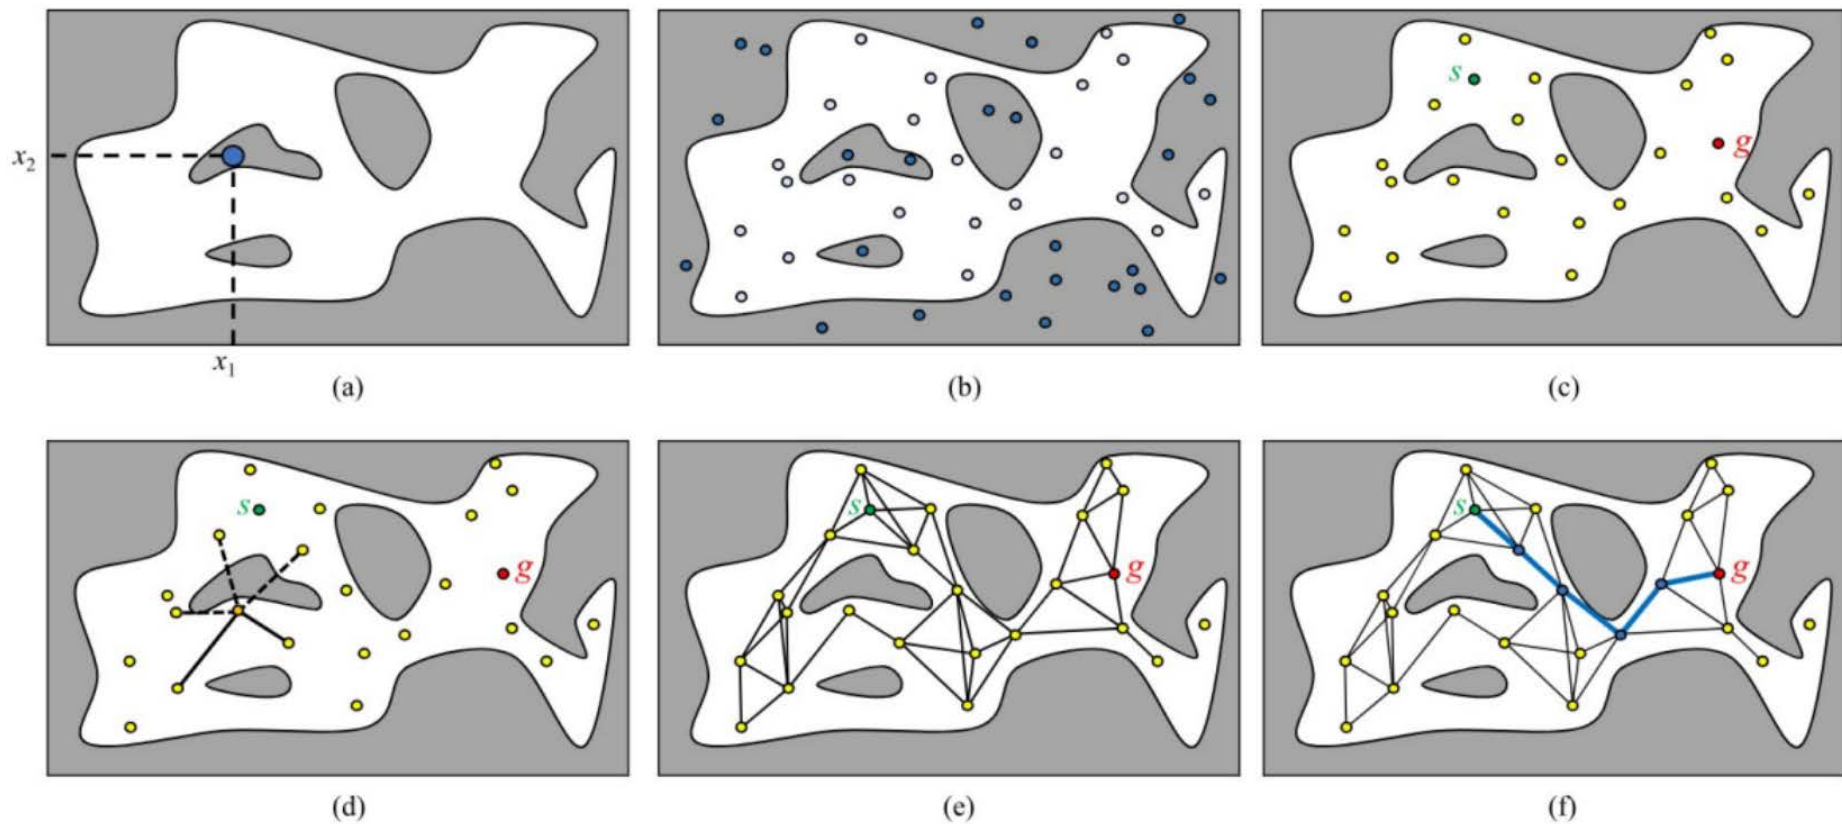




图 10: PRM 算法流程示意图 [4]。 (a) 随机采样; (b) feasibility 检测; (c) 保留 feasible 的点, 添加初始和目标点; (d) visibility 检测; (d) 形成最终的路标图; (e) 进行图搜索。

- 基于采样的算法
 - PRM

建图



图搜索



- 基于采样的算法

- PRM

- PRM中**建图**的过程是主要的时间开销来源，当建好图后，可以很高效地得到图中**任意**两个节点之间的可行路径，所以其属于**multi-query**方法。
 - PRM是概率性算法，是**概率完备**的（probabilistically complete）：如果问题有解，则随着采样点的增加，算法找到一个可行路径的概率逐渐趋近于 1。
 - 影响算法性能的因素：
 - 如何进行随机采样？
 - 可修改 PRM 中的采样分布以提升规划效率。
 - 如何找到一个路标点（顶点）附近的路标点？
 - 最近邻搜索问题（k-d tree ...）。



- **基于采样的算法**
 - **Rapidly-exploring random trees (RRT)**
 - single-query, 即只需要得到初始状态到目标状态的路径。
 - 基本思想：从初始状态开始 q_s 扩展一棵树 \mathcal{T} , 逐渐（随机）探索整个空间, 直到扩展到达目标节点 q_g 。


- 基于采样的算法

- Rapidly-exploring random trees (RRT)

- Goal bias: 以一定概率 p_{goalbias} 选择 q_g 替代 q_{rand} 来引导树扩展。根据经验, 一般 p_{goalbias} 选择 0.05 至 0.1 是比较合适的。
 - 与 PRM 算法不同, RRT 算法并不会将随机采样得到的状态用在路径中, 而只是用随机采样的状态来引导树扩展的方向。
 - RRT 算法也是概率完备的, 而且其算法实现简便, 非常易于添加其它约束, 所以应用十分广泛。
 - 缺点:
 - 在复杂场景中效率不够高。
 - 得到的路径常常十分曲折 (非最优) 。

- 基于采样的算法
 - Rapidly-exploring random trees (RRT)


RRT过程示意视频 (youtube)




- 基于采样的算法

- Bidirectional RRT (双向RRT)

- 目的：提高规划效率。
 - 基本思想：其从 q_s 和 q_g 同时长出两棵树，相向探索，从而提高扩展效率。
当两棵树连起来时，即为找到可行路径。



bug trap





- 基于采样的算法

- 小结:

- 既可以用于低维空间，也可以用于高维空间。应用广泛。
 - 可以非常方便地加入其它局部约束，例如实现末端位姿约束的机械臂规划。
 - 还可以加入微分约束来实现 kinodynamic planning。
 - 实现简便，但其性能往往受到很多细节的影响，实际应用时往往需要调整超参数来达到最优的性能。
 - 主要用于找到可行路径，而非严格最优路径。



- **机械臂路径规划 (path planning for manipulators) 的特点**
 - 维度高。
 - free configuration space (C_{free}) 难以描述。
 - 考虑 configuration space (joint space) 与 task space (cartesian space)。
- **常用的方法:**
 - 复杂任务/障碍物: sampling-based planning.
 - 简单任务/障碍物: potential field methods / optimization-based planning.

• 关节空间目标的路径规划

- 机械臂路径规划的目标是定义在关节空间，即指定了 q_g ，则问题和上一节中讨论的构型空间中的路径规划是一致的。
- 常用的方法是 PRM、RRT 及其多种变种。一般来说，Bidirectional RRT 的时间开销会比普通 RRT 要小很多。
- 适当的距离度量：对不同关节加权。
- 机械臂几何模型复杂，碰撞检测较为复杂，碰撞检测的时间开销在规划的总开销中的占比是很大的。常用 FCL (Flexible Collision Library) 库。


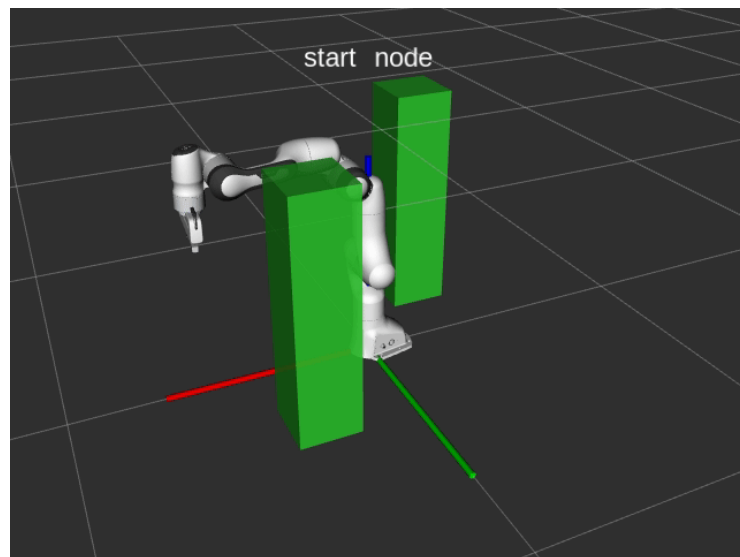


图 16: 基于 Bidirectional RRT 的机械臂路径规划及操作 [9]。

- 任务空间目标的路径规划

- 只指定了机械臂末端的目标位姿。

- 最简单的方法：先对 task-space goal 求 IK，得到 joint-space goal，再使用前文方法。
 - Problem：IK多解，选择哪一个解？不合适的解可能是不可达的。





Fig. 2. Two inverse kinematics solutions for the same end-effector posture.




Fig. 3. 3-DOF robot and configuration space with a C-obstacle creating two disconnected components of free space.




Fig. 4. Two IK solutions (a) and (b) lying in disconnected components of the configuration space.

• 任务空间目标的路径规划

• 第一类方法:

- 无需显式 IK, 使用 task-space goal 引导 RRT 探索。

• 基本思想:

- 在每次 RRT 迭代中, 以一定概率按RRT方式扩展 (no goal bias) 。
- 以一定概率进行 ExtendTowardsGoal():
 - 选择离 goal pose 最近的节点, 基于 Jacobian 矩阵的转置, 向 goal pose 扩展 (optimal local controller) 。

• 优劣:

- 不需要显式的逆运动学求解。

GrowRRT()

```
2   $Q_{new} = \{q_{start}\};$ 
3  while (DistanceToGoal( $Q_{new}$ ) > distanceThreshold)
4     $p = \text{RandomReal}([0.0, 1.0]);$ 
5    if ( $p < p_g$ )
6       $Q_{new} = \text{ExtendTowardsGoal}();$ 
7    else
8       $Q_{new} = \text{ExtendRandomly}();$ 
9    if ( $Q_{new} \neq \emptyset$ )
10     AddNodes( $Q_{new}$ )
```

ExtendTowardsGoal()

```
11   $q_{old} = \text{ClosestNodeToGoal}();$ 
12  repeat
13     $J^T = \text{JacobianTranspose}(q_{old});$ 
14     $\delta_x = \text{WorkspaceDelta}(q_{old}, x_{goal});$ 
15     $\delta_q = J^T \cdot \delta_x;$ 
16     $q_{new} = q_{old} + \delta_q;$ 
17    if (CollisionFree( $q_{old}, q_{new}$ ))
18       $Q_{new} = Q_{new} \cup q_{new};$ 
19    else
20      return  $Q_{new};$ 
21     $q_{old} = q_{new};$ 
22  while (DistanceToGoal( $q_{new}$ ) > distanceThreshold)
23  return  $Q_{new};$ 
```

- 任务空间目标的路径规划

- 第二类方法:

- 在 RRT 过程中不断采样 task-space goal 对应的 IK 解。
- 基本思想:
 - 每次迭代中, 以一定概率采样 goal pose 及其对应的 IK , 添加进 goal tree 中。
- 优劣:
 - 可以使用 bidirectional RRT, 提高效率。
 - 需要非常高效的 IK 求解器。


Algorithm 3: IK-RRT(q_{start}, p_{obj}, gc)

```
1 RRT1.AddConfiguration( $q_{start}$ );
2 RRT2.Clear();
3 while (!Timeout()) do
4   if ( $\#IK\ Solutions == 0 \parallel rand() < p_{IK}$ ) then
5      $grasp \leftarrow GetRandomGrasp(gc)$ ;
6      $p_{target} \leftarrow ComputeTargetPose(p_{obj}, grasp)$ ;
7      $q_{IK} \leftarrow ComputeIK(p_{target})$ ;
8     if (!Collision( $q_{IK}$ )) then
9       RRT2.AddConfiguration( $q_{IK}$ );
10    else
11       $q_r \leftarrow GetRandomConfiguration()$ ;
12      if
13        ( $RRT1.Connect(q_r) \& RRT2.Connect.(q_r)$ )
14      then
15         $Solution \leftarrow BuildSolutionPath(q_r)$ ;
16        return PrunePath( $Solution$ );
17      end
18    end
19  end
20 end
```


- 任务空间目标的路径规划

- 两类方法对比:

- 第一类方法更适合简单的环境或机械臂逆运动学求解困难的情况，因为其不需要显式的逆运动学求解，而且其扩展方式是局部最优的。
- 第二类方法更适合于环境复杂、但可以高效机械臂逆运动学求解的情况，因为其可以使用 Bidirectional RRT，从而极大提高复杂环境中的规划效率。



(a)



(b)

	Without Obstacle Avg Runtime	With Obstacle Avg Runtime
J^+ -RRT	2 032 ms	18 390 ms
IK-RRT	140 ms	480 ms

图 18: 两类任务空间目标的路径规划方法的对比 [14]。其中 J^+ -RRT 属于第一类不需要显式逆运动学求解的方法，IKRRT 属于第二类随机采样逆运动学解的方法。(a) 对于同一任务的 RRT 树扩展过程对比；(b) 规划时间开销对比。

- **本章没有介绍的内容：**
 - 涉及微分约束的路径（轨迹）规划，即 kinodynamic planning。例如对于固定翼飞机、阿克曼转向的车辆（如小汽车）等的规划。
 - 涉及动态障碍物的路径（轨迹）规划。
 - 最优规划。

- **相关课程资源：**

- **书籍：**

- Siciliano, “Robotics Modeling, Planning and Control”, 2009. 该书是机器人领域的经典教材，包括机器人从建模、规划、控制全方位的基础知识。其中第 12 章为 Motion Planning，篇幅较短，可用于初步了解机器人运动规划的概念和方法。
 - Lavelle, “ Planning Algorithms”, 2006. 该书是 Planning 领域最全面的教材，作者Lavelle 是 RRT 及其多种变种的提出者。该书理论扎实、内容全面，适合用于极为深入地学习运动规划理论；但本书成书较早，无法包含近期的研究成果。该书可在线获取：<http://lavelle.pl/planning/>。

- **课程：**

- “Robotic Systems”, UIUC, Keris Hauser, <https://motion.cs.illinois.edu/RoboticSystems/>. 其中第三章为 Motion Planning。该部分提供了详细的讲义，架构清晰，内容适中，易于阅读（非常推荐）。
 - “Motion Planning”, University of Michigan, Dmitry Berenson, <https://berenson.robotics.umich.edu/courses/winter2022motionplanning/index.html>. 该课程提供 slides，内容全面，链接了很多其它相关学习资料，且涉及一些较新的研究成果。