

产生式系统的搜索

**状态空间法(S,F,G)**(初始状态 操作符 目标状态)  
如食人生番:动作 op(b1,b2,b3)(人数,野人数,哪岸到哪岸)  
状态(a1,a2,a3)(左岸人 num,左岸野人 num,船在左 or 右)  
状态转换:  $A \rightarrow B$ ,  $OPERATOR$ (操作对象,初值,终值)  
**搜索**:宽/深:后代放进 open-后代是否目标-取点放进 closed  
**一致代价搜索**: Dijkstra 算法。  
**贪婪最优搜索**:仅利用启发函数作为代价。  
**A\*算法**:  $f(n) = h(n) + g(n)$   
最优性:可采纳: 树搜索的 A\*, 一致: 图搜索的 A\*  
可采纳性:  $h(n) \leq h^*(n)$ ; 一致性:  $h(n) \leq c(n,n') + h(n')$   
/深度优先:  $h(n) = 0, g(n) = d(n)$   
/一致代价  $h(n) = 0, f(n) = g(n) + 0$   
/宽度优先:  $h(n)$  足够大,  $g(n) = 0, f(n) = h(n)$   
**计算复杂性**  $f(x) = O(g(x)) \Leftrightarrow \exists A, B > 0, A \leq |f/g| \leq B$   
**P类问题**:有多项式时间算法解决的**判定问题**(有  $P \subseteq NP$ )  
**NP类问题**:对猜想存在多项式时间算法来验证的判定问题, 非确定性多项式问题  
**NP完全问题**: (NP中最难的问题)判定问题  $P_1 \in NP$ , 对所有其他判定问题  $P_m \in NP$ , 有  $P_m \propto P_1$ , 则  $P_1$  是 NP 完全的。  
**NP难题**:  $P_1 \propto P_2, P_1 \in NP \Rightarrow P_2$  是 NP 难的。  $P_2$  至少和  $P_1$  一样难。如 TSP 问题不是判定问题, 但它是 NP 难题。  
**约束满足问题和搜索**:  
**约束满足问题**:变量 X、值域 D、约束 C。  
**回溯搜索**: 一次赋值一个变量, 合法时从该状态继续为下一变量赋值, 没有合法值则返回父节点尝试新赋值/选择顺序: 最少剩余值、最多约束项、最少约束值  
**推理**: 节点相容 (变量在其值域中的所有取值均满足其一元约束)、边相容 (变量在其值域中的所有取值均满足与该变量相关的二元约束)、k-相容、路径相容。  
**搜索后推理**: 在变量赋值后对它进行边相容检查, 删除与该变量相关的未赋值变量不相容的值, 冲突时回溯。  
**局部搜索**: 爬山法: 从初始状态开始, 不断向 h(n) 函数值增加的状态移动/随机梯度下降: 一次用一个样例计算梯度  
**博弈树搜索**: 画与或图, 我方或、MAX, 对方与、MIN  
**与或图**: 注意弧线! 有弧线是与, 没弧线是或。  
叶节点一定可解; 非叶节点: 若含有或(与)后继点, 那么至少一个(全部)后继可解时, 该非叶节点可解。  
非叶节点无后继不可解/或(与)后继全不(有一个)可解。  
**极大极小搜索**: 我方取后继的 MAX, 对方取后继的 MIN。  
 $\alpha - \beta$  剪枝: 用深搜。  $\alpha$  是 MAX 的下界;  $\beta$  是 MIN 的上界。  
 $\alpha: \beta$ (后继层)  $\leq \alpha$ (先辈层), 中止该 MIN 层后续搜索;  
 $\beta: \alpha$ (后继层)  $\geq \beta$ (先辈层), 中止该 MAX 层后续搜索。  
效率: 设深度为 P, 每节点有 B 个后继, 生成端节点最小值  $N_p$ 。  
 $p$  为偶数:  $N_p = 2B^{p/2} - 1$ ;  $p$  为奇数:  $N_p = B^{(p+1)/2} + B^{(p-1)/2} - 1$   
**蒙特卡洛树搜索**: 权重  $I_j = \bar{v}_j + c \sqrt{\ln N / n_j}$  (N 是总访问次数)  $n_j, \bar{v}_j$  算法开始到现在, 节点 j 被访问的次数和平均收益  
流程: 选择-拓展-模拟-反向传播

谓词逻辑与归结原理:命题是具有唯一真值的陈述句。

2.  $\wedge$ :合取(与)  $\vee$ :析取(或)  $\rightarrow$ :蕴含  $\leftrightarrow$ :等价  
3.  $p \rightarrow q$  为假当且仅当  $p = T, q = F$   
4. 永真/重言式:真; 永假/矛盾式:假; 可满足式:至少一个成真赋值; **非重言式的可满足式**:至少一个成真一个成假  
5. 吸收律:  $A \vee (A \wedge B) \Leftrightarrow A; A \wedge (A \vee B) \Leftrightarrow A$   
 $A \vee (B \wedge C) \Leftrightarrow (A \vee B) \wedge (A \vee C)$   
 $A \wedge (B \vee C) \Leftrightarrow (A \wedge B) \vee (A \wedge C)$   
 $\sim (A \vee B) \Leftrightarrow B \wedge \sim A, \sim (A \wedge B) \Leftrightarrow B \vee \sim A$   
**重要**:  $A \rightarrow B \Leftrightarrow \sim A \vee B, (A \rightarrow B) \wedge (A \rightarrow \sim B) \Leftrightarrow \sim A$   
 $A \leftrightarrow B \Leftrightarrow (A \rightarrow B) \wedge (B \rightarrow A)$   
 $A \rightarrow B \Leftrightarrow \sim B \rightarrow \sim A, A \leftrightarrow B \Leftrightarrow \sim A \leftrightarrow \sim B$   
6. 原子公式: 不含任何联结词的公式//子句: 任何文字的析取式; 文字: 原子或~原子//合取**范式**: 简单析取式构成的合取式//析取范式: 简单合取式构成的析取式  
**命题逻辑的推理规则**  
7. 附加:  $A \Rightarrow (A \vee B)$ ; 假言推理:  $((A \rightarrow B) \wedge A) \Rightarrow B$   
简化:  $(A \wedge B) \Rightarrow A$ ; 拒取式:  $((A \rightarrow B) \wedge \sim B) \Rightarrow \sim A$   
析取三段论:  $((A \vee B) \wedge \sim A) \Rightarrow B$   
假言三段论:  $((A \rightarrow B) \wedge (B \rightarrow C)) \Rightarrow (A \rightarrow C)$   
等价三段论:  $((A \leftrightarrow B) \wedge (B \leftrightarrow C)) \Rightarrow (A \leftrightarrow C)$   
构造性二难:  $(A \rightarrow B) \vee (C \rightarrow D) \wedge (A \vee C) \Rightarrow (B \vee D)$   
可做: 前提引入/结论引入/置换规则比如  $\sim p \vee q$  换  $p \rightarrow q$   
**命题逻辑的归结方法**  
8. 子句: 简单析取式, 项是一个变量或者其否定。  
子句集: 合取范式中所有子句的集合,  $\wedge$  换成“ $\vee$ ”。  
9. 归结原理: 如  $p \vee q$  和  $\sim p \vee r$  都为真, 那么  $q \vee r$  为真。  
10. 归结式:  $C_1 = P \vee C_1', C_2 = \sim P \vee C_2'$  归结  $C_{12} = C_1' \vee C_2'$   
11. **归结 (消解) 法**: 为了证明  $A \rightarrow B$  真, 先转为  $A \wedge \sim B$ , 证明该命题公式永假。提取其子句集, 归结为空即可。  
**谓词逻辑** 12. 个体词/谓词 任意/存在量词 约束出现/自由出现//函数是个体域到个体域的映射, 不同于谓词  
13. 换名: 辖域中约束出现的变量名换掉/替代: 自由出现的

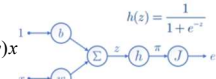
个体变量名字可换掉

14. 谓词公式永真称为逻辑有效/永真的, 谓词公式永假成为不一致/不可满足。  
15. **谓词演算公式**  $\sim(\forall x)P(x) \Leftrightarrow (\exists y)\sim P(y)$   
 $\sim(\exists x)P(x) \Leftrightarrow (\forall y)\sim P(y)$   
 $(\forall x)(P(x) \wedge Q(x)) \Leftrightarrow (\forall x)P(x) \wedge (\forall x)Q(x)$   
 $(\exists x)(P(x) \vee Q(x)) \Leftrightarrow (\exists x)P(x) \vee (\exists x)Q(x)$   
 $(\forall x)(P(x) \rightarrow Q) \Leftrightarrow (\exists x)P(x) \rightarrow Q$   
 $(\forall x)(Q \rightarrow P(x)) \Leftrightarrow Q \rightarrow (\forall x)P(x)$   
 $(\exists x)(P(x) \rightarrow Q) \Leftrightarrow (\forall x)P(x) \rightarrow Q$   
 $(\exists x)(Q \rightarrow P(x)) \Leftrightarrow Q \rightarrow (\exists x)P(x)$   
注意:  $(\exists x)(P(x) \wedge Q(x)) \neq (\exists x)P(x) \wedge (\exists x)Q(x)$   
 $(\forall x)(P(x) \vee Q(x)) \neq (\forall x)P(x) \wedge (\exists x)Q(x)$   
16. **前束范式**: 将量词均提到最左边  
17. 谓词推理: 存在用常量替代, 任意用变量 or 常量替代  
**谓词逻辑归结原理**  
18. skolem 标准型: 变前束范式; 消去存在量词; 略去全称量词例子:  $\forall x \exists y P(x, y) \rightarrow \forall x P(x, f(x)) \quad | \quad \exists x f(x) \rightarrow f(c)$   
19. **置换**:  $\theta = \{t_1/a_1, \dots\}$ , 用  $t_i$  代替  $a_i$   
结合律  $(\theta \cdot \lambda_1) \lambda_2 = \theta(\lambda_1 \cdot \lambda_2)$ , 不满足交换律。  
20. 合一:  $F = \{F_1, F_2, \dots\}$ , 存在置换  $\theta$ , 使  $F_i \theta = F_j \theta \dots$ 。  
21. **最一般合一**:  $\alpha$  是 F 的最一般合一置换, 那 F 的任一合一  $\theta$ , 都有置换  $\lambda$ , 有  $\theta = \alpha \lambda$  (从左比较对应项不同就换)  
22. **归结过程**: 归谬-化取范式-子句集-归结-空子句。

**最大似然估计**:  $Y_i = ax_i + b + \varepsilon_i, Y_i | x_i \sim N(ax_i + b, \sigma^2)$

概率密度函数:  $f(y_i | a, b, x_i) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{[y_i - (ax_i + b)]^2}{2\sigma^2}\right\}$   
 $l = \log L = \log \prod_{i=1}^n f = -\frac{n \log(2\pi)}{2} - n \log(\sigma) - \frac{1}{2\sigma^2} \sum_{i=1}^n [y_i - (ax_i + b)]^2$   
去找使似然函数值  $l$  最大的参数值, 结果同最小二乘法。  
参数  $\hat{a} = \frac{S_{xy}}{S_{xx}} = \sum \frac{x_i - \bar{x}}{S_{xx}} Y_i, \hat{a} \sim N\left(a, \frac{\sigma^2}{S_{xx}}\right), \frac{\hat{a} - a}{\sqrt{\sigma^2 / S_{xx}}} \sim N(0, 1)$   
 $\hat{b} = \bar{Y} - \hat{a}\bar{x} \sim N(b, \sigma^2 / n S_{xx} \sum x_i^2), \varepsilon_i \sim N(0, \sigma^2)$   
**假设检验**:  $H_0: \omega = 0$  vs  $H_1: \omega \neq 0, p = 2\Phi(|\hat{\omega}| / \sqrt{\sigma^2 / S_{xx}})$   
P 小 H1 真, 检验越合理。  $\sum (y_i - \bar{y})^2 = \sum (\hat{y}_i - \bar{y})^2 + \sum (y_i - \hat{y}_i)^2$   
**确定系数**:  $r^2 = S_{\hat{y}}^2 / (S_{\hat{y}}^2 + S_{\varepsilon}^2)$ , 越接近 1 拟合效果越好  
**多项式回归**:  $y = \omega_0 + \omega_1 x + \omega_2 x^2 + \dots + \omega_m x^m, y = Xw$   
**多元回归**:  $y = \omega_0 + \omega_1 x_1 + \omega_2 x_2 + \dots + \omega_m x_m, y = Xw$   
 $y = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix}, X = \begin{pmatrix} 1 & \cdots & x_{1m} \\ 1 & x_{21} & \cdots & x_{2m} \\ \vdots & \ddots & \ddots & \vdots \\ 1 & x_{n1} & \cdots & x_{nm} \end{pmatrix}, W = \begin{pmatrix} \omega_0 \\ \vdots \\ \omega_m \end{pmatrix}, \min(y - Xw)^T (y - Xw) \Rightarrow w = (X^T X)^{-1} X^T y$

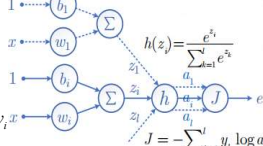
监督学习: Logistic 回归

**L 回归**:  $y = \pi(x) = \frac{1}{1 + \exp\{-wx + b\}}, \pi'(x) = w\pi(x)(1 - \pi(x))$   
 $P(Y = 1) = 1 / (1 + \exp\{-(wx + b)\}) = \pi(x), P(Y = 0) = 1 - \pi(x)$   
 $\log \frac{P(Y = 1)}{1 - P(Y = 1)} = wx + b, e^w = \frac{\pi(x+1)/(1 - \pi(x+1))}{\pi(x)/(1 - \pi(x))}$   
**对数似然**:  $L(w, b | x, y) = f(y | w, b, x) = \prod_{i=1}^n \pi^{y_i}(x_i)(1 - \pi(x_i))^{1 - y_i}$   
 $l(w, b | x, y) = \sum_{i=1}^n -H(p_i, q_i)$ , 需要  $\max \sum_{i=1}^n -H(p_i, q_i)$   
**经验损失**:  $J(w, b) = \frac{1}{n} \sum_{i=1}^n H(p_i, q_i)$ , 需要  $\min \frac{1}{n} \sum_{i=1}^n H(p_i, q_i)$   
交叉熵  $H(p, q) = -y_i \log \pi(x_i) - (1 - y_i) \log(1 - \pi(x_i))$   
梯度下降找最小:  $x^{new} \leftarrow x - \alpha f'(x)$   
  
 $\frac{de}{dw} = \frac{de}{d\pi} \frac{d\pi}{dz} \frac{dz}{dw} = \pi - y, \frac{de}{dw} = (\pi - y)x$   
 $\frac{de}{d\pi} = -\frac{y}{\pi} + \frac{1-y}{1-\pi}, \frac{d\pi}{dz} = \frac{1}{1+e^{-z}} \frac{e^{-z}}{1+e^{-z}} = \pi(1-\pi)$  | 从输出算梯度  
**二分类的评价**  
T/F: True / False ; P / N : Positive / Negative; R : Rate  
TPR = TP / (TP + FN); FPR = FP / (TN + FP); TNR = TN / (TN + FP)  
FNR = FN / (TP + FN); 敏感 Sensitivity = TPR; 1-Sensitivity = FNR  
特异 Specificity = TNR; 1-Specificity = FPR; Fall-out = FP / (TP + FP)  
精度 Precision = TP / (TP + FP); 召回率 Recall = TP / (TP + FN);  
F1-score = 2TP / (2TP + FP + FN) = 2\*P\*R / (P + R) | P/R: 精度/召回  
Accuracy = (TP + TN) / (TP + TN + FN + TN);  
BER = 1/2(FPR + FNR); BCR = 1/2(TPR + TNR)

MCC:  $(TP \cdot TN - FP \cdot FN) / \sqrt{(TP + FP)(FP + TN)(TN + FN)(FN + TP)}$

混淆矩阵		真实结果	
		Positive	Negative
预测结果	Chaim Posi	TP	FP
	Chaim Nega	FN	TN

**softmax 回归**:  $P(Y = k) = e^{w_k x + b_k} / \sum_{j=1}^J e^{w_j x + b_j} = \pi_k(x)$

$\max \sum_{i=1}^n \sum_{k=1}^J y_{ik} \log \pi_k(x_i)$   
 $\min -\frac{1}{n} \sum_{i=1}^n \sum_{k=1}^J y_{ik} \log \pi_k(x_i)$   
  
 $\frac{de}{dw_i} = -\sum_{k=1}^J \frac{\partial e}{\partial \pi_k} \frac{\partial \pi_k}{\partial z_i} \frac{\partial z_i}{\partial w_i} = \pi_i - y_i, x$   
 $\frac{de}{dw_i} = (\pi_i - y_i)x, \frac{d\pi_k}{dz_i} = \begin{cases} e^{z_i}, k = i \\ 0, k \neq i \end{cases}, \frac{\partial e}{\partial \pi_k} = -\frac{y_k}{\pi_k}, \frac{\partial z_i}{\partial b_i} = 1, \frac{\partial z_i}{\partial w_i} = x$   
**一元变多元**:  $w x + b \leftarrow \sum_{j=1}^m w_j x_j, w_k x + b_k \leftarrow \sum_{j=1}^m w_{jk} x_j$

前馈神经网络:输入单元—隐层单元—输出单元

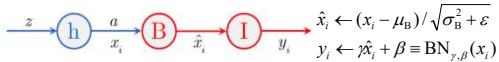
**线性单元**:  $x = (x_1, x_2, \dots, x_m)^T, w = (w_1, w_2, \dots, w_m)^T$   
 $z = w^T x + b, \frac{da}{dw} = \frac{da}{dz} \frac{dz}{dw} = 1 \cdot 1, \frac{da}{dw} = \frac{da}{dz} \frac{dz}{dw} = 1 \cdot x^T$   
 $a = z$   
**Logistic 单元**:  $z = w^T x + b, a = 1 / (1 + e^{-z})$   
 $\frac{\partial a}{\partial b} = \frac{da}{dz} \frac{dz}{\partial b} = a(1 - a), \frac{\partial a}{\partial w} = \frac{da}{dz} \frac{dz}{\partial w} = a(1 - a)x^T$   
**Softmax**:  $w_i = (w_{i1}, \dots, w_{im})^T, W = (w_1, \dots, w_m), b = (b_1, \dots, b_m)^T$   
 $z = Wx + b, a = \frac{\exp(z)}{\sum_{k=1}^r \exp(z_k)}, a_i = \frac{e^{z_i}}{\sum_{k=1}^r e^{z_k}}, e = -y^T \log a$   
 $z_i = W_{[i]} x + b_i, J_{ew} = \left( \frac{\partial e}{\partial a_i} \right)_{i \in [r]} \left( \frac{\partial a_i}{\partial z_i} \right)_{i \in [r]} \left( \frac{\partial z_i}{\partial w_{jk}} \right)_{j \in [r], k \in [r, m]} = \left( \frac{\partial e}{\partial w_{jk}} \right)_{j \in [r], k \in [r, m]}, J_{eb} = \left( \frac{\partial e}{\partial b_j} \right)_{j \in [r]}$

双曲正切单元:  $a = (\mathrm{e}^z - \mathrm{e}^{-z})/(\mathrm{e}^z + \mathrm{e}^{-z})$ ,  $da/db = 1 - a^2$   
整流线性单元(ReLU):  $a = \max(0, z)$ ,  $da/dz = 1, z > 0; 0, \text{other}$   
梯度消失问题略优。其他隐层单元:  $\text{softplus } a = \log(1 + \mathrm{e}^z)$   
输入单元—隐层单元(一般 ReLU)—输出单元(按需选)  
网络结构设计:可表示区域的数量是深度的指数函数(d 深度,每个隐层 k 单元 m 输入):  $O(k^m((k-m)^r)^{m(d-1)})$   
随机梯度下降:一次用一个样例更新梯度(SGD)

动量梯度下降位移导是速度  $v(t) = \frac{\partial}{\partial t} d(t)$ , 速度导是受力  $f(t) = \frac{\partial}{\partial t} v(t)$ , 将位移类比参数  $\Delta \theta \propto v$ , 受力类比负梯度  $\Delta v \propto -\nabla_{\theta}$ 。参数更新公式:  $v \leftarrow \alpha v - \varepsilon \nabla_{\theta}$ ,  $\theta \leftarrow \theta + v$   
Nesterov 动量:  $\hat{\theta} \leftarrow \theta + \alpha v$ ,  $v \leftarrow \alpha v - \varepsilon \nabla_{\hat{\theta}}$ ,  $\theta \leftarrow \theta + v$

参数初始化策略  
破坏对称性:与同一个输入相连的具有相同激活函数的隐层单元参数不同; 随机初始化:权重随机产生,偏置设为零  
学习速率调整方法:学习速率反比于梯度累计平方和的根线性衰减:  $\alpha_k = \begin{cases} \lambda \alpha_r + (1-\lambda) \alpha_0, & k \leq r \\ \alpha_r, & k > r \end{cases}$ ,  $\lambda = \frac{k}{\tau}$  //自适应衰减:

AdaGrad (Duchi et al., 2011) Adam (Kingma and Ba, 2016)  
$$\begin{aligned} \mathbf{r} &\leftarrow \mathbf{r} + \mathbf{g} \odot \mathbf{g} & \mathbf{s} &\leftarrow \rho_1 \mathbf{s} + (1 - \rho_1) \mathbf{g} \\ \boldsymbol{\theta} &\leftarrow \boldsymbol{\theta} - \frac{\epsilon}{\delta + \sqrt{\mathbf{r}}} \odot \mathbf{g} & \mathbf{r} &\leftarrow \rho_2 \mathbf{r} + (1 - \rho_2) \mathbf{g} \odot \mathbf{g} \\ & & \hat{\mathbf{s}} &\leftarrow \frac{\mathbf{s}}{1 - \rho_1^k} \\ \text{RMSProp (Hinton, 2012)} & & \hat{\mathbf{r}} &\leftarrow \frac{\mathbf{r}}{1 - \rho_1^k} \\ \mathbf{r} &\leftarrow \rho r + (1 - \rho) \mathbf{g} \odot \mathbf{g} & \boldsymbol{\theta} &\leftarrow \boldsymbol{\theta} - \frac{\epsilon}{\delta + \sqrt{\hat{\mathbf{r}}}} \odot \hat{\mathbf{s}} \\ \boldsymbol{\theta} &\leftarrow \boldsymbol{\theta} - \frac{\epsilon}{\delta + \sqrt{\mathbf{r}}} \odot \mathbf{g} & & \end{aligned}$$

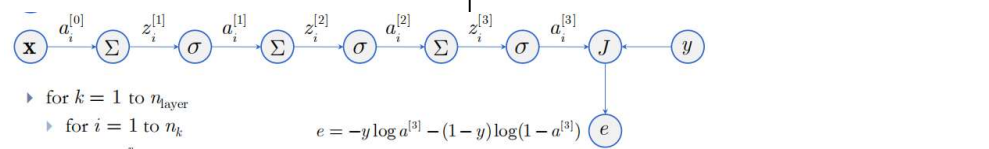
正则化:增加数据/提前终止/修改目标函数加入惩罚项  
简化网络结构:随机扔掉一些节点/连接  
批次标准化:SGD 过程中对隐层输出标准化,可以用较大学习率/提升训练速度/收敛快/性能好(类似扔节点的正则化方法)/初始参数要求低  $\mu_B \leftarrow 1/m \sum x_i$ ,  $\sigma_B^2 \leftarrow 1/m \sum (x_i - \mu_B)^2$   


卷积神经网络  
卷积:填充:允许卷积核超出边界(Samepadding)如边缘补 0。  
稀疏连接:可以用全连接的前馈网络实现,不参与卷积的点权重为 0。节点 N, 卷积核 m\*m, 连接  $O(m^2 N)$   
参数共享:在不同位置卷积时像素点一样则结果一样(等变表示), 局部特征为制不重要,  $O(m^2)$ 。  
非共享卷积核/平铺卷积核:不共享参数/不完全共享参数  
1\*1 卷积核可以降低/多个卷积核升维/减少计算量  
池化:用某一位置相邻输出的统计特征代替该位置的输出。  
池化函数:最大池化/平均池化/随机池化  
步长大于 1 的池化能够降低输入规模。  
卷积神经网络典型结构:卷积层、池化层叠起来,再由全连接网络完成相关学习。卷积功能:特征提取—端到端学习。  
训练过程:前向/后向,关键是池化和卷积单元的梯度计算。数据的扩增:原图抽取小图、原图进行几何变换等。  
图卷积模型:  $x_i^{(com)} \leftarrow w_i x_v + \sum_{u \in \mathcal{N}(i)} w_u x_u$ , u 是邻居

强化学习  
马尔可夫过程:二元组  $(S, P)$  状态空间  $S = \{s_1, \dots, s_n\}$   
状态转移矩阵  $P = (p_{ss'})_{n \times n}$ ,  $p_{ss'} = P(S_{t+1} = s' | S_t = s)$   
马尔可夫回报过程:四元组  $(S, P, r, \gamma)$   
状态转移  $S_t \rightarrow S_{t+1}$  产生回报  $R_{t+1}$ 。折现因子  $\gamma \in [0, 1]$ ; 期望状态回报  $r = \{r_1, r_2, \dots, r_n\}$ ,  $r_s = E[R_{t+1} | S_t = s] = \sum_{r \in R} rp(r | S_t = s)$   
累计回报:  $G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1}$   
状态价值函数:  $v(s) = E[G_t | S_t = s] = r_s + \gamma \sum_{s' \in S} p_{ss'} v(s')$   
贝尔曼期望方程:  $v = r + \gamma P v$ ,  $v = (I - \gamma P)^{-1} r$   
马尔可夫决策过程:五元组  $(S, A, P, R, \gamma)$   
行动  $A_t$  导致状态转移  $S_t \rightarrow S_{t+1}$  产生回报  $R_{t+1}$  行动空间:  $A = \{a_1, a_2, \dots, a_m\}$ ; 状态转移矩阵:  $P = (p_{ss'})_{n \times n \times m}$  其中  $p_{ss'}^a = P(S_{t+1} = s' | S_t = s, A_t = a) = \sum_{r \in R} p(s', r | s, a)$ ; 行动期望回报  $R = (r_s^a)_{n \times m}$ ,  $r_s^a = E[R_{t+1} | S_t = s, A_t = a] = \sum_{r \in R} r p(s', r | s, a)$   
策略:  $\pi(a | s) = P(A_t = a | S_t = s)$ , s 下选策略 a 的概率。  
 $p^{\pi}(S_{t+1} = s' | S_t = s) = \sum_{a \in A} \pi(a | s) p_{ss'}^a$ ,  $r_s^{\pi} = \sum_{a \in A} \pi(a | s) r_s^a$   
状态价值:  $v_{\pi}(s) = E[G_t | S_t = s] = \sum_{a \in A} \pi(a | s) q_{\pi}(s, a)$   
行动价值:由后续状态价值的加权和计算。  
 $q_{\pi}(s, a) = E[G_t | S_t = s, A_t = a] = r_s^a + \gamma \sum_{s' \in S} p_{ss'}^a v_{\pi}(s')$

贝..期望方程:  $v_{\pi}(s) = \sum_{a \in A} \pi(a | s) (r_s^a + \gamma \sum_{s' \in S} p_{ss'}^a v_{\pi}(s'))$   
 $q_{\pi}(s, a) = r_s^a + \gamma \sum_{s' \in S} p_{ss'}^a \sum_{a' \in A} \pi(a' | s') q_{\pi}(s', a')$   
矩阵形式:  $v = r^{\pi} + \gamma P^{\pi} v$ ,  $v = (I - \gamma P^{\pi})^{-1} r^{\pi}$   
动态规划—策略评价(状态价值计算)、策略改进  
 $v^{(k+1)} = r^{\pi} + \gamma P^{\pi} v^{(k)}$ ,  $v_{k+1}(s) = r_s^{\pi} + \gamma \sum_{s' \in S} p_{ss'}^{\pi} v_k(s')$   
最优状态价值:  $v_{*}(s) = \max_{\pi} v_{\pi}(s) = v_{\pi_{*}}(s)$   
最优行动价值:  $q_{*}(s, a) = \max_{\pi} q_{\pi}(s, a) = q_{\pi_{*}}(s, a)$   
最优 a 价值是同时刻最优 q 价值  $v_{*}(s) = \max_a q_{*}(s, a)$   
最优策略(贪心策略):  $\pi_{*}(a | s) = 1$ , if  $a = \arg \max q_{*}(s, a)$   
策略迭代:已知策略 pi, 用动态规划计算出各个行动下的状态价值 v (直至收敛,或者算一步改进一次), 在某状态可行的所有策略中选择使得状态价值最大的那个(贪心策略), 然后重复以上过程, 得到一系列状态、策略。  $v_{k+1}(s) = \max_{a \in A} (r_s^{\pi} + \gamma \sum_{s' \in S} p_{ss'}^{\pi} v_k(s'))$   
同步迭代:算完所有 s 更新一次策略。(不用算 v 至收敛)  
异步迭代:算完一个 s 就更新一次策略。

蒙特卡洛—无 P 矩阵时状态价值预测、策略改进  
已知观测片段,对某个状态 S, 以其出现作为开始计算出这些幕各自的  $G_i$ , 对这些  $G_i$  取平均值来估计  $v(s)$ 。 $V(S_t) = 1/n \sum G_i$ , 其中  $G_i = R_{t+1} + \gamma R_{t+2} + \dots + \gamma^{T-t} R_{T+1}$   
首次访问/每次访问:作为起始的 s 是否第一次出现。  
增量式蒙特卡洛:  $V(S_t) \leftarrow V(S_t) + 1/k (G_t - V(S_t))$ ,  $k \leftarrow k + 1$   
定步长蒙特卡洛:  $V(S_t) \leftarrow V(S_t) + \alpha (G_t - V(S_t))$   
无模型时预测行动价值,  $q_{\pi}(s, a) \approx 1/n \sum G_i$   
增量式:  $Q(S_t, A_t) \leftarrow Q(S_t, A_t) + 1/k (G_t - Q(S_t, A_t))$ ,  $k \leftarrow k + 1$   
定步长:  $Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha (G_t - Q(S_t, A_t))$   
策略改进:  $\pi^{\pi}(S_t) = \arg \max_{a \in A} Q(S_t, a)$   
贪心改进:  $\pi_{*}(a | s) = \begin{cases} 1 - \varepsilon + \varepsilon / m, & \text{if } a = \arg \max q_{*}(s, a) \\ \varepsilon / m, & \text{otherwise} \end{cases}$   
时序差分—从部分序列学习  
递推状态价值:  $V(S_t) \leftarrow V(S_t) + \alpha (R_{t+1} + \gamma V(S_{t+1}) - V(S_t))$   
蒙从完整序列学习,适用带终止的决策过程/离线学习(必须获得完整片段来估计累计汇报)/非马更有效; 时序从部分序列学习,可用于无终止状态的决策过程/在线学习,只需获取下一状态的及时回报/马环境更有效。

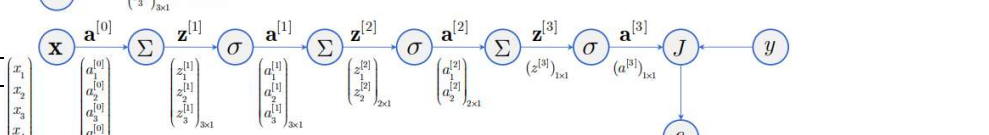


for  $k = 1$  to  $n_{\text{layer}}$   
for  $i = 1$  to  $n_k$

$$z_i^{[k]} = \sum_{j=1}^{n_{i-1}} w_{ij}^{[k]} a_j^{[k-1]} + b_i^{[k]}$$
$$a_i^{[k]} = \sigma(z_i^{[k]})$$

非常慢

一行: 本层的一个神经元  
一列: 前层的一个神经元

$$e = -y \log a^{[3]} - (1 - y) \log (1 - a^{[3]})$$
$$\mathbf{W}^{[k]} = \begin{pmatrix} w_{11}^{[k]} & w_{12}^{[k]} & w_{13}^{[k]} & w_{14}^{[k]} \\ w_{21}^{[k]} & w_{22}^{[k]} & w_{23}^{[k]} & w_{24}^{[k]} \\ w_{31}^{[k]} & w_{32}^{[k]} & w_{33}^{[k]} & w_{34}^{[k]} \end{pmatrix}_{3 \times 4}$$
$$\mathbf{b}^{[1]} = \begin{pmatrix} b_1^{[1]} \\ b_2^{[1]} \\ b_3^{[1]} \end{pmatrix}_{3 \times 1}$$
$$\mathbf{b}^{[2]} = \begin{pmatrix} b_1^{[2]} \\ b_2^{[2]} \end{pmatrix}_{2 \times 1}$$
$$\mathbf{W}^{[3]} = \begin{pmatrix} w_{11}^{[3]} & w_{12}^{[3]} \\ w_{21}^{[3]} & w_{22}^{[3]} \end{pmatrix}_{2 \times 2}$$
$$\mathbf{b}^{[3]} = \begin{pmatrix} b_1^{[3]} \\ b_2^{[3]} \end{pmatrix}_{2 \times 1}$$

$$\mathbf{z}^{[1]} = (\mathbf{b}^{[1]} \quad \mathbf{W}^{[1]}) \begin{pmatrix} 1 \\ \mathbf{a}^{[0]} \end{pmatrix}$$
$$\mathbf{z}^{[2]} = (\mathbf{b}^{[2]} \quad \mathbf{W}^{[2]}) \begin{pmatrix} 1 \\ \mathbf{a}^{[1]} \end{pmatrix}$$
$$\mathbf{z}^{[3]} = (\mathbf{b}^{[3]} \quad \mathbf{W}^{[3]}) \begin{pmatrix} 1 \\ \mathbf{a}^{[2]} \end{pmatrix}$$
$$\mathbf{a}^{[1]} = \sigma(\mathbf{z}^{[1]}) \quad \mathbf{a}^{[2]} = \sigma(\mathbf{z}^{[2]}) \quad \mathbf{a}^{[3]} = \sigma(\mathbf{z}^{[3]})$$
$$\frac{\partial e}{\partial \mathbf{b}^{[3]}} = \frac{de}{da^{[3]}} \frac{da^{[3]}}{dz^{[3]}} \frac{\partial z^{[3]}}{\partial \mathbf{b}^{[3]}} = \left( -\frac{y}{a^{[3]}} + \frac{1-y}{1-a^{[3]}} \right) a^{[3]} (1-a^{[3]}) = a^{[3]} - y$$
$$\frac{\partial e}{\partial \mathbf{W}^{[3]}} = \frac{de}{da^{[3]}} \frac{da^{[3]}}{dz^{[3]}} \frac{\partial z^{[3]}}{\partial \mathbf{W}^{[3]}} = (a^{[3]} - y) (\mathbf{a}^{[2]})^T$$
$$\frac{\partial e}{da^{[3]}} = -\frac{y}{a^{[3]}} + \frac{1-y}{1-a^{[3]}}$$
$$\frac{da^{[3]}}{dz^{[3]}} = a^{[3]} (1 - a^{[3]})$$
$$\frac{\partial z^{[3]}}{\partial \mathbf{b}^{[3]}} = 1 \quad \frac{\partial z^{[3]}}{\partial \mathbf{W}^{[3]}} = (\mathbf{a}^{[2]})^T$$
$$\frac{\partial e}{\partial \mathbf{W}^{[2]}} = \frac{de}{da^{[3]}} \frac{da^{[3]}}{dz^{[3]}} \frac{\partial z^{[3]}}{\partial a_2^{[2]}} \frac{\partial a_2^{[2]}}{\partial \mathbf{W}^{[2]}} = \left( -\frac{y}{a^{[3]}} + \frac{1-y}{1-a^{[3]}} \right) a^{[3]} (1-a^{[3]}) \mathbf{W}^{[3]} \begin{pmatrix} a_1^{[2]} (1-a_1^{[2]}) \\ a_2^{[2]} (1-a_2^{[2]}) \end{pmatrix} \begin{pmatrix} (\mathbf{a}^{[1]})^T \\ (\mathbf{a}^{[1]})^T \end{pmatrix}$$

1×6	根据最终需要的维度解释	1×1	1×1	1×2	2×2	2×6
$\frac{de}{da^{[3]}} = -\frac{y}{a^{[3]}} + \frac{1-y}{1-a^{[3]}}$	$\frac{\partial z^{[3]}}{\partial a_2^{[2]}} = \mathbf{W}^{[3]}$	$\frac{\partial z^{[2]}}{\partial \mathbf{W}^{[2]}} = \begin{pmatrix} (\mathbf{a}^{[1]})^T \\ (\mathbf{a}^{[1]})^T \end{pmatrix}$	$\mathbf{W}^{[1]} = (w_{ij}^{[1]})_{3 \times 4}$	$\mathbf{W}^{[2]} = (w_{ij}^{[2]})_{2 \times 3}$	$\mathbf{W}^{[3]} = (w_{ij}^{[3]})_{2 \times 2}$	
$\frac{da^{[3]}}{dz^{[3]}} = a^{[3]} (1 - a^{[3]})$	$\frac{\partial \mathbf{a}^{[2]}}{\partial z^{[2]}} = \begin{pmatrix} a_1^{[2]} (1 - a_1^{[2]}) \\ a_2^{[2]} (1 - a_2^{[2]}) \end{pmatrix}$					