


1

a)



b)

斜率: 4.54

截距: 20.97

r^2 的计算基于以下几个统计量:

- 总平方和 (Total Sum of Squares, SST) :

$$SST = \sum_{i=1}^n (y_i - \bar{y})^2$$

- 回归平方和 (Regression Sum of Squares, SSR) :

$$SSR = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$$

- 残差平方和 (Residual Sum of Squares, SSE) :

$$SSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

通过以下公式计算：

$$r^2 = \frac{SSR}{SST} = \frac{545.14}{591.95} = 0.921$$

含义：

r^2 的值范围从 0 到 1。值越接近 1，表示模型对数据的拟合越好，解释的变异越多，例如 $r^2 = 0.80$ 可以解释为模型通过自变量解释了因变量 80% 的变异。

c)

$$MAE = \frac{1}{10} (|20.23 - 22.77| + |27.90 - 23.83| + \dots + |46.58 - 44.33|)$$

$$MAE \approx 1.95$$

$$MSE = \frac{1}{10}((20.23 - 22.77)^2 + (27.90 - 23.83)^2 + \dots + (46.58 - 44.33)^2)$$

$$MSE \approx 4.68$$

MAE和MSE的数值都比较小，表示模型对数据有着较好的拟合效果，误差水平控制得较好。

d)

$$SST = \sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n [(y_i - \hat{y}_i) + (\hat{y}_i - \bar{y})]^2$$

展开右边的平方项

$$SST = \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + 2 \sum_{i=1}^n (y_i - \hat{y}_i)(\hat{y}_i - \bar{y})$$

根据残差平方和最小这一估计条件，对回归方程系数进行求偏导：

$$\begin{aligned} \sum_{i=1}^n (y_i - \hat{y}_i) &= 0 \\ \sum_{i=1}^n (y_i - \hat{y}_i)x_i &= 0 \end{aligned}$$

$$\sum_{i=1}^n (y_i - \hat{y})(\hat{y} - \bar{y}) = \sum_{i=1}^n (y_i - \hat{y})(wx_i + b) - \sum_{i=1}^n (y_i - \hat{y})\bar{y} = 0$$

因此 SST=SSR+SSE

根据之前的计算：

$$\text{SST}=591.95$$

$$\text{SSR}=545.14$$

$$\text{SSE}=46.81$$

验证关系：

$$\text{SST} \approx \text{SSR} + \text{SSE}, \text{ 即 } 591.95 \approx 545.14 + 46.81$$

2

在二元逻辑回归的对数模型中，预测事件 $y=1$ 的概率模型为

$$\log \left(\frac{P(y = 1 \mid x)}{1 - P(y = 1 \mid x)} \right) = \beta^T x$$

从而

$$P(y = 1 \mid x) = \frac{e^{\beta^T x}}{1 + e^{\beta^T x}}$$

我们可以定义第*i*个样本属于第*k*类的对数概率为：

$$\log P(y^{(i)} = k) = \beta_k^T x_i - \log Z$$

这里logZ是归一化因子，确保通过指数化和归一化后的所有类别概率之和为1：

$$Z = \sum_{j=1}^K e^{\beta_j^T x_i}$$

将对数形式转换为概率的形式，我们得到Softmax回归模型：

$$P(y^{(i)} = k) = \frac{e^{\beta_k^T x_i}}{Z}$$

3

a)

给定输入 x_1 ，Softmax模型首先计算每个类别的得分：

$$z_k = w_k x_1 + b_k$$

输出为类别 k 的概率为：

$$P(y = k \mid x_1) = \frac{e^{z_k}}{\sum_{j=1}^l e^{z_j}}$$

交叉熵损失：

$$L = - \sum_{k=1}^l y_{1k} \log P(y = k \mid x_1)$$

其中 y_{1k} 表示当 y_1 确实为类别 k 的时候取1，否则取0.

使用梯度下降求解该模型，要求损失 L 对 z_k 的偏导数，我们先考虑 $P(y = k|x_1)$ 的偏导数。根据链式法则：

$$\frac{\partial L}{\partial w_k} = \frac{\partial L}{\partial P(y=k|x_1)} \cdot \frac{\partial P(y=k|x_1)}{\partial z_k} \cdot \frac{\partial z_k}{\partial w_k}$$

$$= x_1 \cdot (P(y = k | x_1) - y_{1k})$$

$$\frac{\partial L}{\partial b_k} = 1 \cdot (P(y = k | x_1) - y_{1k})$$

b)

计算出梯度后更新参数：

$$w_k = w_k - \alpha \cdot \frac{\partial L}{\partial w_k}$$

$$b_k = b_k - \alpha \cdot \frac{\partial L}{\partial b_k}$$